

Technische Universität Wien
Department für Geodäsie und Geoinformation
Studiengang: Umweltingenieurwesen

Exposé zur Bachelorarbeit

Zeitserie Pielach:

Konzeption und Implementierung einer
STAC-Architektur für multi-temporale räumliche
Datensätze

Verfasser: Jules Vlasich

Matrikelnummer: 12105601

Betreuer: Prof. Dipl.-Ing. Dr. Gottfried Mandlbürger

Datum: 5. Mai 2026

Inhaltsverzeichnis

1	Einleitung und Motivation	2
2	Problemstellung und Forschungsfragen	3
3	Stand der Forschung und Technik	4
4	Methodisches Vorgehen	5
5	Zielsetzung und Erwartete Ergebnisse	6
6	Vorläufige Gliederung	8

1 Einleitung und Motivation

Am Department für Geodäsie und Geoinformation der TU Wien wird seit über einem Jahrzehnt eine Geodaten-Zeitreihe des Flussgebiets der Pielach geführt [1, 2]. Der Datenbestand umfasst mittlerweile zahlreiche topo-bathymetrische LiDAR-Befliegungen mit den jeweils abgeleiteten Produkten: Punktwolken, digitale Höhenmodelle, Orthophotos. Diese Daten bilden eine essenzielle Grundlage für verschiedenste Anwendungen wie etwa Hochwassermodellierung, morphologische Analysen und Vegetationsmonitoring. Da neue Befliegungen und abgeleitete Produkte fortlaufend hinzukommen, wächst der Bestand kontinuierlich an, und mit ihm die Herausforderung, einzelne Datensätze gezielt aufzufinden. Wer heute etwa alle Höhenmodelle eines bestimmten Bereichs über mehrere Jahre hinweg vergleichen möchte, muss sich manuell durch heterogene Verzeichnisstrukturen und projektspezifische Namenskonventionen arbeiten, bevor die eigentliche Analyse beginnen kann.

Dieses Problem ist kein Einzelfall. In den vergangenen Jahren ist eine kontinuierliche Zunahme an Erdbeobachtungs- und Geodaten zu verzeichnen, deren Nutzung zunehmend nach den FAIR-Data-Principles ausgerichtet wird, also an einer Bereitstellung, die für Menschen wie Maschinen auffindbar, zugänglich, interoperabel und wiederverwendbar ist [3]. Um die enormen Datenmengen der modernen Erdbeobachtung effizient verarbeiten zu können, findet derzeit ein Paradigmenwechsel statt: Weg vom traditionellen Herunterladen lokaler Dateien, hin zu *Cloud-Native-Geospatial*-Ansätzen. Eine zwingende Voraussetzung für diese cloud-basierten Workflows sind maschinenlesbare, standardisierte Metadaten, die ein gezieltes Durchsuchen und Filtern der riesigen Datenbestände überhaupt erst ermöglichen. Genau an dieser Stelle setzt der SpatioTemporal Asset Catalog (STAC) an: Er etabliert eine einheitliche, auf Webservices ausgerichtete Spezifikation zur Beschreibung von Geodaten und fungiert somit als zentrales Bindeglied, um räumlich-zeitliche Datensätze interoperabel und effizient zugänglich zu machen [4, 5, 6].

Die Pielach-Zeitreihe stellt ein ideales Anwendungsszenario dar, um die Potenziale einer solchen STAC-basierten Dateninfrastruktur zu demonstrieren: Der Datenbestand ist heterogen in Formaten und Auflösungen, wächst kontinuierlich und dient bereits heute als Grundlage aktiver Forschung [7]. Eine geeignete Dateninfrastruktur muss daher von Beginn an darauf ausgelegt sein, künftige Datensätze ohne strukturellen Umbau aufzunehmen.

2 Problemstellung und Forschungsfragen

Bislang liegen historische und kontinuierlich wachsende Datenbestände wie die Pielach-Zeitreihe häufig in hierarchischen Ordnersystemen vor, ohne einen standardisierten, maschinenlesbaren Index. Da die raumzeitlichen Metadaten in solchen rein verzeichnisorientierten Ablagen nicht zentral erfasst und verknüpft sind, erschwert dies eine automatisierte Abfrage massiv und führt dazu, dass Anwender viel Zeit in die manuelle Datensuche, Vorverarbeitung und Harmonisierung investieren müssen, bevor die eigentliche Analyse beginnen kann.

Erschwerend kommt hinzu, dass die zugrunde liegenden Verarbeitungsketten typischerweise heterogene Outputs hinterlassen: Punktwolken, abgeleitete Höhenmodelle und Orthophotos folgen oft projektspezifischen Namenskonventionen und liegen in unterschiedlichen Formaten vor. Eine Überführung dieser Daten in ein STAC-konformes Modell erfordert daher nicht nur eine durchdachte Katalogarchitektur, sondern auch eine automatisierte und konfigurierbare Pipeline für die Metadatenextraktion und Katalogerweiterung.

Um das volle Potenzial solcher multitemporalen Datensätze auszuschöpfen und sie für komplexe raumzeitliche Analysen nahtlos verfügbar zu machen, bedarf es einer modernen Dateninfrastruktur. Die Lücke zwischen einem unstrukturierten Rohdatenbestand und einer effizienten, *Cloud-Native*-gestützten Auswertung stellt ein zentrales Hindernis im aktuellen Geodatenmanagement dar.

Aus dieser Problemstellung ergeben sich für die vorliegende Bachelorarbeit die folgenden zentralen Forschungsfragen:

- 1 Wie ist ein statischer STAC-Katalog zu konzipieren, der eine heterogene, kontinuierlich wachsende Geodaten-Zeitreihe mit massiven Unterschieden in Datentyp, Auflösung und Speicherbedarf langfristig erweiterbar und standardkonform abbildet?
- 2 Inwieweit lässt sich die Generierung und Erweiterung eines solchen Katalogs so automatisieren und parametrisieren, dass die Pipeline ohne Code-Änderungen auf abweichende Datenbestände und Namenskonventionen anwendbar bleibt?
- 3 Welchen konkreten Mehrwert bietet der erzeugte STAC-Katalog gegenüber einer rein verzeichnisorientierten Ablage für domänenspezifische raumzeitliche Abfragen, wie etwa die Selektion aller Datensätze entlang eines definierten Gewässerabschnitts?

3 Stand der Forschung und Technik

Ein fundamentales Konzept der modernen Geodatenbereitstellung bilden cloud-optimierte Datenformate, die gezielt nur jene Datenbereiche abrufen lassen, die für eine spezifische Analyse benötigt werden. Für Rasterdaten hat sich das *Cloud Optimized GeoTIFF* (COG) [8] als Standard etabliert, im Bereich der Punktwolken nimmt das *Cloud Optimized Point Cloud* Format (COPC) [9] eine analoge Rolle ein: Es organisiert LAZ-komprimierte Punktwolken in einer Octree-Struktur [10], sodass räumlich begrenzte Abfragen ohne vollständiges Herunterladen möglich werden.

Um solche dezentralen Datenbestände durchsuchbar zu machen, existieren unterschiedliche Metadatenstandards. Der etablierte Standard ISO 19115 [11] bietet ein umfassendes, aber entsprechend komplexes Schema. Als leichtgewichtige, webzentrierte Alternative hat sich der SpatioTemporal Asset Catalog (STAC) durchgesetzt [4]: *Items* repräsentieren atomare raumzeitliche Datensätze und verweisen auf die eigentlichen *Assets*, welche in *Collections* gruppiert und in übergeordneten *Catalogs* organisiert werden. Statische STAC-Kataloge können als reine JSON-Dateien ohne Serverinfrastruktur bereitgestellt und bei Bedarf in bestehende STAC-API-Server überführt werden. Für ihre programmatische Erstellung hat sich die Python-Bibliothek PySTAC etabliert [12].

Ein konzeptionell verwandter Ansatz ist das *Data-Cube*-Paradigma, etwa im Rahmen der Open Data Cube Initiative [13, 14]. *Data Cubes* organisieren Daten in mehrdimensionalen Arrays mit einheitlicher Auflösung und Projektion, was für homogene Satellitenbildzeitreihen gut geeignet ist, jedoch eine Homogenisierung der Quelldaten voraussetzt. Für den vorliegenden Anwendungsfall mit heterogenen Datentypen und stark variierenden Speicheranforderungen eignet sich der formatagnostische Ansatz von STAC besser.

Die spezifische Herausforderung, multi-temporale Punktwolkendaten systematisch zu verwalten, wurde bislang nur vereinzelt adressiert. Rieg et al. [15] beschreiben eine datenbankgestützte Infrastruktur für wiederholte ALS-Befliegungen in hochalpinen Umgebungen. Ihr Ansatz entstand jedoch vor der Verfügbarkeit von STAC und cloud-optimierten Formaten und setzt eine lokale Datenbankinfrastruktur voraus, die sich nicht ohne Weiteres auf webbasierte Bereitstellungsszenarien übertragen lässt. Die vorliegende Arbeit knüpft an diese Fragestellung an.

Als Untersuchungsgegenstand dient die Pielach-Zeitreihe, die mittlerweile über ein Jahrzehnt topo-bathymetrischer LiDAR-Befliegungen umfasst [2, 1]. Seit Beginn der Zeitreihe wurde der Datensatz kontinuierlich erweitert, unter anderem durch UAV-getragene Sensorplattformen [16]. Artikel wie etwa die multi-temporale Streifenausgleichung durch Wimmer et al. [7] unterstreichen zudem den wachsenden analytischen Anspruch an den Datenbestand.

4 Methodisches Vorgehen

Das methodische Vorgehen dieser Arbeit gliedert sich in fünf aufeinander aufbauenden Phasen. Den konzeptionellen und implementierungstechnischen Kern bilden dabei die Phasen 3 und 4 (Katalogarchitektur und Generierungspipeline), während die Datenaufbereitung (Phase 2) als vorbereitende Stufe und die Abfrage- und *Subsetting*-Komponente (Phase 5) als Demonstration der erzeugten Infrastruktur fungieren.

- 1 Anforderungsanalyse und Technologieauswahl:** Zunächst wird ermittelt, welche Metadaten für die Pielach-Zeitreihe relevant sind und welche STAC-Erweiterungen zur vollständigen Beschreibung der Daten benötigt werden (z. B. Projection-, Pointcloud- und Raster-Erweiterung). Dazu zählen unter anderem räumliche *Footprints*, Zeitstempel, Koordinatenreferenzsysteme, Punktdichten und Attributschemata für Punktwolken sowie Bandparameter für Rasterprodukte. Parallel dazu erfolgt die Evaluierung und Auswahl geeigneter Softwarekomponenten für die automatisierte Metadatenextraktion (insbesondere OPALS, PDAL und GDAL) und die Erstellung des statischen STAC-Katalogs.
- 2 Datenaufbereitung (*Pre-Processing*):** In der Vorbereitungsphase werden die Rohdaten in *Cloud-Native*-Formate (wie beispielsweise COG) überführt. Dieser Schritt umfasst zudem die Evaluierung und Umsetzung geeigneter Kachelungs-Strategien (*Spatial Partitioning*). Dabei wird ein hybrider Ansatz untersucht, bei dem speicherintensive Punktwolken räumlich gekachelt und in COPC überführt werden, während abgeleitete, weniger speicherintensive Rasterprodukte als ungekachelte COGs belassen werden, um Metadaten-Overhead zu vermeiden.
- 3 Konzeption der STAC-Architektur:** Die Entwicklung der strukturellen Katalog-Hierarchie stellt den konzeptionellen Kern der Arbeit dar. Dabei wird detailliert evaluiert, wie die verschiedenen Jahresdatensätze, Datenprodukte und insbesondere die etwaigen gekachelten Daten (*Tiles*) logisch, skalierbar und standardkonform abgebildet werden können. Ein zentrales Architekturprinzip ist die Erweiterbarkeit: Da die Pielach-Zeitreihe kontinuierlich um neue Befliegungen wächst, muss der Katalog jederzeit ohne strukturellen Umbau um zusätzliche Datensätze ergänzbar sein. Ebenfalls Gegenstand dieser Phase ist die Evaluierung geeigneter *Linking*-Strategien, insbesondere die Frage, ob und in welchem Umfang *Asset*-Referenzen als relative oder absolute Pfade ausgestaltet werden sollten, um die Portabilität des Katalogs bei gleichzeitiger Anbindung an bestehende Datenspeicher zu gewährleisten.

4 Implementierung: Auf Basis der zuvor getroffenen Entscheidungen wird die eigentliche Generierungspipeline aufgebaut. Diese liest einen Verzeichnisbaum mit Verarbeitungs-Outputs ein, extrahiert die nötigen Metadaten programmatisch über Python-Schnittstellen und erzeugt daraus einen standardkonformen, statischen STAC-Katalog. Eine konfigurierbare *Asset-Registry* ermöglicht es, die Zuordnung zwischen Dateikonventionen und semantischen *Asset*-Kategorien ohne Code-Änderungen anzupassen und neue Datenkategorien zu späteren Zeitpunkten zu ergänzen. Die Pipeline wird idempotent konzipiert: Bei wiederholter Ausführung auf denselben Datenbestand werden keine redundanten Einträge erzeugt; neue Datensätze werden in den bestehenden Katalog aufgenommen und vorhandene Einträge bei Bedarf aktualisiert.

Die Validierung des erzeugten Katalogs erfolgt auf zwei Ebenen: Zum einen wird die formale STAC-Konformität durch automatisierte Validierungswerkzeuge (PySTAC, stac-validator) geprüft. Zum anderen wird eine inhaltliche Plausibilitätsprüfung durchgeführt, die sicherstellt, dass die extrahierten Metadaten (*Bounding Boxes*, Zeitstempel, CRS-Angaben) mit den tatsächlichen Daten übereinstimmen.

Die Implementierung erfolgt iterativ: Zunächst wird die Pipeline an einem repräsentativen *Subset* (einem ausgewählten Jahresdatensatz) als *Proof of Concept* entwickelt und validiert. Die Programmlogik wird dabei von Beginn an so abstrahiert und parametrisiert, dass sie im Anschluss nahtlos auf die gesamte über zehnjährige Zeitreihe angewendet werden kann.

5 Domänspezifische Abfrage und *Subsetting*: Aufbauend auf dem erzeugten Katalog wird eine Abfrage- und *Subsetting*-Komponente entwickelt, die den praktischen Mehrwert der STAC-basierten Infrastruktur gegenüber einer rein verzeichnisorientierten Ablage demonstriert. Als zentraler Anwendungsfall dient die Identifikation aller Datensätze entlang eines definierten Gewässerabschnitts (z. B. 2 km flussaufwärts eines Referenzpunktes).

5 Zielsetzung und Erwartete Ergebnisse

Das primäre Ziel dieser Arbeit ist die Konzeption und Implementierung einer modernen, Metadaten-gestützten Dateninfrastruktur für die raumzeitlichen Datensätze des Pielach-Gebiets. Konkret umfasst dies eine automatisierte Pipeline zur Generierung und kontinuierlichen Erweiterung eines statischen STAC-Katalogs sowie eine darauf aufbauende Abfrage- und *Subsetting*-Komponente.

1. Technische *Deliverables*

- **Pre-Processing-Komponente:** Entwicklung von Python-basierten Skripten zur automatisierten Überführung der Rohdaten in *Cloud-Native*-Formate (inklusive etwaigem *Tiling*) als Vorstufe der Katalog-Generierung.
- **Generierungs-Pipeline und STAC-Katalog der Pielach-Zeitreihe:** Aufbau einer automatisierten Pipeline, die die vorhandenen Verarbeitungs-Outputs einliest, ihre Metadaten programmatisch extrahiert und einen hierarchisch strukturierten, gegen STAC 1.1 validen Katalog erzeugt. Die Pipeline soll mit einer konfigurierbaren *Asset-Registry* arbeiten und idempotent konzipiert sein, sodass neue Befliegungen in den bestehenden Katalog aufgenommen werden können, ohne vorhandene Strukturen redundant neu zu schreiben.
- **Domänenspezifische Abfrage- und *Subsetting*-Komponente:** Implementierung einer Abfragelogik, die raumzeitliche STAC-Metadaten mit topologischen Informationen zum Gewässernetz kombiniert, um z. B. alle Datensätze entlang eines definierten Gewässerabschnitts flussaufwärts eines Referenzpunktes zu identifizieren.

2. Wissenschaftliche Ergebnisse

- **Begründete Architekturentscheidungen:** Die Arbeit liefert eine dokumentierte und nachvollziehbar begründete Katalogarchitektur für heterogene, multi-temporale Geodaten-Zeitreihen. Dazu zählen insbesondere die Wahl der Katalog-Hierarchie, die Evaluierung geeigneter STAC-Erweiterungen und Kachelungsstrategien sowie die Entscheidung für eine *Linking*-Strategie. Die getroffenen Entscheidungen werden als übertragbare Referenz aufbereitet, die auch für vergleichbare Datenbestände außerhalb des Pielach-Kontexts herangezogen werden kann.
- **Bewertung der Generalisierbarkeit:** Durch die konfigurierbare Gestaltung der Pipeline wird untersucht, inwieweit der gewählte Ansatz auf Datenbestände mit abweichenden Namenskonventionen und Produktstrukturen anwendbar ist. Die Grenzen dieser Generalisierbarkeit werden kritisch dokumentiert.
- **Nachweis des Mehrwerts gegenüber verzeichnisorientierter Ablage:** Anhand der domänenspezifischen Abfrage-Komponente wird konkret demonstriert, welche raumzeitlichen Selektionen durch den STAC-Katalog ermöglicht werden, die mit einer herkömmlichen Ordnerstruktur nicht oder nur mit erheblichem manuellem Aufwand umsetzbar wären. Diese Ergebnisse werden ergänzend mit Bezug auf die FAIR-Prinzipien diskutiert.

6 Vorläufige Gliederung

0. Präambel: Zeitserie Pielach

1. Einleitung

2. Grundlagen und Stand der Technik

2.1 *Cloud-Native-Geospatial* (COG, COPC und HTTP-Range-Requests)

2.2 Metadatenstandards: Von ISO 19115 zu STAC

2.3 Abgrenzung zum *Data-Cube*-Paradigma

2.4 Verwandte Arbeiten und Werkzeuge

3. Technische Ausgangslage der Rohdaten

3.1 Analyse der Verzeichnisstruktur und Dateiformate

3.2 Metadaten-Inkonsistenzen und programmatische Herausforderungen

4. Konzeption der STAC-Architektur

4.1 Strukturierung der Katalog-Hierarchie

4.2 Evaluierung der *Linking*-Strategie

4.3 Erweiterbarkeit und Idempotenz der Pipeline

4.4 Architektur der Abfrage- und *Subsetting*-Komponente

5. Implementierung

5.1 Datenaufbereitung und Überführung in *Cloud-Native*-Formate

5.2 Generierungspipeline (Metadatenextraktion, konfigurierbare *Asset-Registry*)

5.3 Validierung (STAC-Konformität und inhaltliche Plausibilität)

5.4 Domänenspezifische Abfragen und *Subsetting*

6. Ergebnisse und Evaluierung

6.1 Präsentation des generierten STAC-Katalogs

6.2 Domänenspezifische raumzeitliche Abfragen und *Subsetting*

6.3 Bewertung der Generalisierbarkeit der Pipeline

7. Diskussion

7.1 Architekturentscheidungen: Begründung und Übertragbarkeit

7.2 Grenzen der Generalisierbarkeit und Konfigurierbarkeit

7.3 Mehrwert gegenüber verzeichnisorientierter Ablage und FAIR-Bezug

8. Fazit und Ausblick

Vorläufiges Literaturverzeichnis

- [1] Gottfried Mandlbürger u. a. „Topo-Bathymetric LiDAR for Monitoring River Morphodynamics and Instream Habitats — A Case Study at the Pielach River“. In: *Remote Sensing* 7.5 (2015), S. 6160–6195. DOI: [10.3390/rs70506160](https://doi.org/10.3390/rs70506160). URL: <https://doi.org/10.3390/rs70506160>.
- [2] Gottfried Mandlbürger u. a. „A Decade of Progress in Topo-Bathymetric Laser Scanning Exemplified by the Pielach River Dataset“. In: *ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences*. Bd. X-1/W1-2023. 2023, S. 1123–1130. DOI: [10.5194/isprs-annals-X-1-W1-2023-1123-2023](https://isprs-annals.copernicus.org/articles/X-1-W1-2023/1123/2023/). URL: <https://isprs-annals.copernicus.org/articles/X-1-W1-2023/1123/2023/>.
- [3] Mark D. Wilkinson u. a. „The FAIR Guiding Principles for scientific data management and stewardship“. In: *Scientific Data* 3.1 (2016), S. 160018. DOI: [10.1038/sdata.2016.18](https://doi.org/10.1038/sdata.2016.18). URL: <https://doi.org/10.1038/sdata.2016.18>.
- [4] Radiant Earth Foundation und STAC Community. *SpatioTemporal Asset Catalog (STAC) Specification, Version 1.1.0*. <https://github.com/radianteearth/stac-spec>. Offizielles GitHub-Repository der STAC-Kern-Spezifikation (Item, Catalog, Collection). 2024.
- [5] Matt Hanson. *STAC: A Retrospective, Part 1*. Element 84. 28. März 2023. URL: <https://element84.com/geospatial/stac-a-retrospective-part-1/> (besucht am 18.03.2026).
- [6] Matt Hanson. *STAC: A Retrospective, Part 2 (Why STAC was Successful)*. Element 84. 28. Okt. 2025. URL: <https://element84.com/software-engineering/stac-a-retrospective-part-2-why-stac-was-successful/> (besucht am 18.03.2026).
- [7] Michael H. Wimmer u. a. „Strip Adjustment of Multi-Temporal LiDAR Data — A Case Study at the Pielach River“. In: *Remote Sensing* 16.15 (2024), S. 2838. DOI: [10.3390/rs16152838](https://doi.org/10.3390/rs16152838). URL: <https://doi.org/10.3390/rs16152838>.
- [8] Joan Maso u. a. *OGC Cloud Optimized GeoTIFF Standard, Version 1.0*. 21-026. Open Geospatial Consortium. 2023. URL: <https://docs.ogc.org/is/21-026/21-026.html>.
- [9] Andrew Bell, Howard Butler und Connor Manning. *Cloud Optimized Point Cloud Specification 1.0*. <https://copc.io/>. COPC Format-Spezifikation, basierend auf LAZ 1.4 mit clusterierter Octree-Struktur. Hobu, Inc., 2022.
- [10] Jan Elseberg, Dorit Borrmann und Andreas Nüchter. „One billion points in the cloud — an octree for efficient processing of 3D laser scans“. In: *ISPRS Journal of Photogrammetry and Remote Sensing* 76 (2013), S. 76–88. DOI: [10.1016/j.isprsjprs.2012.10.004](https://doi.org/10.1016/j.isprsjprs.2012.10.004).

- [11] International Organization for Standardization. *ISO 19115-1:2014 Geographic information — Metadata — Part 1: Fundamentals*. ISO. Geneva, Switzerland, 2014. URL: <https://www.iso.org/standard/53798.html>.
- [12] stac-utils contributors. *PySTAC: Python library for working with any SpatioTemporal Asset Catalog (STAC)*. <https://github.com/stac-utils/pystac>. Open-Source Python-Bibliothek fuer Erstellung und Verarbeitung von STAC-Metadaten. 2024.
- [13] Brian Killough. „Overview of the Open Data Cube Initiative“. In: *IGARSS 2018 — IEEE International Geoscience and Remote Sensing Symposium*. IEEE, 2018, S. 8629–8632. DOI: [10.1109/IGARSS.2018.8517694](https://doi.org/10.1109/IGARSS.2018.8517694).
- [14] Gregory Giuliani u. a. „Earth Observation Open Science: Enhancing Reproducible Science Through Data Cubes, Cloud Computing, and Machine Learning“. In: *Data* 4.4 (2019), S. 147. DOI: [10.3390/data4040147](https://doi.org/10.3390/data4040147). URL: <https://doi.org/10.3390/data4040147>.
- [15] Lorenzo Rieg u. a. „Data infrastructure for multitemporal airborne LiDAR point cloud analysis – Examples from physical geography in high mountain environments“. In: *Computers, Environment and Urban Systems* 45 (2014), S. 137–146. ISSN: 0198-9715. DOI: <https://doi.org/10.1016/j.compenvurbsys.2013.11.004>. URL: <https://www.sciencedirect.com/science/article/pii/S0198971513001130>.
- [16] Gottfried Mandlbürger u. a. „Concept and Performance Evaluation of a Novel UAV-Borne Topo-Bathymetric LiDAR Sensor“. In: *Remote Sensing* 12.6 (2020), S. 986. DOI: [10.3390/rs12060986](https://doi.org/10.3390/rs12060986). URL: <https://doi.org/10.3390/rs12060986>.